

刘建平Pinard

十年码农，对数学统计学、数据挖掘、机器学习、大数据平台、大数据平台应用开发、大数据可视化感兴趣。

博客园 首页 新随笔 联系 订阅 管理

贝叶斯个性化排序(BPR)算法小结

在矩阵分解在协同过滤推荐算法中的应用中，我们讨论过像funkSVD之类的矩阵分解方法如何用于推荐。今天我们讲另一种在实际产品中用的比较多的推荐算法:贝叶斯个性化排序(Bayesian Personalized Ranking, 以下简称BPR)，它也用到了矩阵分解，但是和funkSVD家族却有很多不同之处。下面我们来详细讨论。

1. BPR算法使用背景

在很多推荐场景中，我们都是基于现有的用户和商品之间的一些数据，得到用户对所有商品的评分，选择高分的商品推荐给用户，这是funkSVD之类算法的做法，使用起来也很有效。但是在有些推荐场景中，我们是为了在千万级别的商品中推荐个位数的商品给用户，此时，我们更关心的是用户来说，哪些极少商品在用户心中有更高的优先级，也就是排序更靠前。也就是说，我们需要一个排序算法，这个算法可以把每个用户对应的所有商品按喜好排序。BPR就是这样的一个我们需要的排序算法。

2. 排序推荐算法背景介绍

排序推荐算法历史很悠久，早在做信息检索的各种产品中就已经在使用了。最早的第一类排序算法类别是点对点方法(Pointwise Approach)，这类算法将排序问题被转化为分类、回归之类的问题，并使用现有分类、回归等方法进行实现。第二类排序算法是成对方法(Pairwise Approach)，在序列方法中，排序被转化为对序列分类或对序列回归。所谓的pair就是成对的排序，比如(a,b)一组表明a比b排的靠前。我们要讲到的BPR就属于这一类。第三类排序算法是列表方法(Listwise Approach)，它采用更加直接的方法对排序问题进行了处理。它在学习和预测过程中都将排序列表作为一个样本。排序的组结构被保持。

本文关注BPR，这里我们对排序推荐算法本身不多讲，如果大家感兴趣，可以阅读李航的A Short Introduction to Learning to Rank。

3. BPR建模思路

在BPR算法中，我们将任意用户u对应的物品进行标记，如果用户u在同时有物品i和j的时候点击了i，那么我们就得到了一个三元组 $\langle u, i, j \rangle$ ，它表示对用户u来说，i的排序要比j靠前。如果对于用户u来说我们有m组这样的反馈，那么我们就可以得到m组用户u对应的训练样本。

既然是基于贝叶斯，那么我们也就有假设，这里的假设有两个：一是每个用户之间的偏好行为相互独立，即用户u在商品i和j之间的偏好和其他用户无关。二是同一用户对不同物品的偏好相互独立，也就是用户u在商品i和j之间的偏好和其他的商品无关。为了便于表述，我们用 $\succ_u$ 符号表示用户u的偏好，上面的 $\langle u, i, j \rangle$ 可以表示为： $i \succ_u j$ 。

在BPR中，这个排序关系符号 $\succ_u$ 满足完全性，反对称性和传递性，即对于用户集U和物品集I：

- 完整性:  $\forall i, j \in I: i \neq j \Rightarrow i \succ_u j \cup j \succ_u i$
- 反对称性:  $\forall i, j \in I: i \succ_u j \cap j \succ_u i \Rightarrow i = j$
- 传递性:  $\forall i, j, k \in I: i \succ_u j \cap j \succ_u k \Rightarrow i \succ_u k$

同时，BPR也用了和funkSVD类似的矩阵分解模型，这里BPR对于用户集U和物品集I的对应的 $U \times I$ 的预测排序矩阵 $\bar{X}$ ，我们期望得到两个分解后的用户矩阵 $W (|U| \times k)$ 和物品矩阵 $H (|I| \times k)$ ，满足

$$\bar{X} = WH^T$$
 MF模型

这里的k和funkSVD类似，也是自己定义的，一般远远小于 $|U|, |I|$ 。

由于BPR是基于用户维度的，所以对于任意一个用户u，对应的任意一个物品i我们期望有：

$$\bar{x}_{ui} = w_u \bullet h_i = \sum_{f=1}^k w_{uf} h_{if}$$

最终我们的目标，是希望寻找合适的矩阵 $W, H$ ，让 $\bar{X}$ 和 $X$ 最相似。读到这里，也许你会说，这和funkSVD之类的矩阵分解模型没有什么区别啊？的确，现在还看不出，下面我们来看看BPR的算法优化思路，就会慢慢理解和funkSVD有什么不同了。

4. BPR的算法优化思路

BPR 基于最大后验估计 $P(W, H | \succ_u)$ 来求解模型参数 $W, H$ ，这里我们用 $\theta$ 来表示参数 $W$ 和 $H$ ， $\succ_u$ 代表用户u对应的所有商品的全序关系，则优化目标是 $P(\theta | \succ_u)$ 。根据贝叶斯公式，我们有：

$$P(\theta | \succ_u) = \frac{P(\succ_u | \theta) P(\theta)}{P(\succ_u)}$$

由于我们求解假设了用户的排序和其他用户无关，那么对于任意一个用户u来说， $P(\succ_u)$ 对所有的物品一样，所以有：

$$P(\theta | \succ_u) \propto P(\succ_u | \theta) P(\theta)$$

这个优化目标转化为两部分。第一部分和样本数据集D有关，第二部分和样本数据集D无关。

对于第一部分，由于我们假设每个用户之间的偏好行为相互独立，同一用户对不同物品的偏好相互独立，所以有：

公告

★珠江追梦，饮岭南茶，恋鄂北情  
你的支持是我写作的动力：



昵称： 刘建平Pinard  
园龄： 4年6个月  
粉丝： 7512  
关注： 16  
+加关注

积分与排名

积分 - 480126  
排名 - 895

随笔分类 (135)

- 0040. 数学统计学(9)
- 0081. 机器学习(71)
- 0082. 深度学习(11)
- 0083. 自然语言处理(23)
- 0084. 强化学习(19)
- 0121. 大数据挖掘(1)
- 0122. 大数据平台(1)

随笔档案 (135)

- 2019年7月(1)
- 2019年6月(1)
- 2019年5月(2)
- 2019年4月(3)
- 2019年3月(2)
- 2019年2月(2)
- 2019年1月(2)
- 2018年12月(1)
- 2018年11月(1)
- 2018年10月(3)
- 2018年9月(3)
- 2018年8月(4)
- 2018年7月(3)
- 2018年6月(3)
- 2018年5月(3)
- 更多

常去的机器学习网站

- 52 NLP
- Analytics Vidhya
- 深度学习进阶书
- 深度学习入门书
- 机器学习路线图
- 机器学习库
- 强化学习入门书

阅读排行榜

$$\prod_{u \in U} P(>_u | \theta) = \prod_{(u,i,j) \in (U \times I \times I)} P(i >_u j | \theta)^{\delta((u,i,j) \in D)} (1 - P(i >_u j | \theta))^{\delta((u,i,j) \notin D)}$$

其中,

$$\delta(b) = \begin{cases} 1 & \text{if } b \text{ is true} \\ 0 & \text{else} \end{cases}$$

根据上面讲到的完整性和反对称性, 优化目标的第一部分可以简化为:

$$\prod_{u \in U} P(>_u | \theta) = \prod_{(u,i,j) \in D} P(i >_u j | \theta)$$

而对于 $P(i >_u j | \theta)$ 这个概率, 我们可以使用下面这个式子来代替:

$$P(i >_u j | \theta) = \sigma(\bar{x}_{uij}(\theta))$$

其中,  $\sigma(x)$ 是sigmoid函数。这里你也许会问, 为什么可以用这个sigmoid函数来代替呢? 其实这里的代替可以选择其他的函数, 不过式子需要满足BPR的完整性, 反对称性和传递性。原文作者这么做除了是满足这三个性质外, 另一个原因是为了方便优化计算。

对于 $\bar{x}_{uij}(\theta)$ 这个式子, 我们要满足当 $i >_u j$ 时,  $\bar{x}_{uij}(\theta) > 0$ , 反之当 $j >_u i$ 时,  $\bar{x}_{uij}(\theta) < 0$ , 最简单的表示这个性质的方法就是

$$\bar{x}_{uij}(\theta) = \bar{x}_{ui}(\theta) - \bar{x}_{uj}(\theta)$$

而 $\bar{x}_{ui}(\theta), \bar{x}_{uj}(\theta)$ , 就是我们的矩阵 $\bar{X}$ 对应位置的值。这里为了方便, 我们不写 $\theta$ , 这样上式可以表示为:

$$\bar{x}_{uij} = \bar{x}_{ui} - \bar{x}_{uj}$$

注意上面的这个式子也不是唯一的, 只要可以满足上面提到的当 $i >_u j$ 时,  $\bar{x}_{uij}(\theta) > 0$ , 以及对应的相反条件即可。这里我们仍然按原文的式子来。

最终, 我们的第一部分优化目标转化为:

$$\prod_{u \in U} P(>_u | \theta) = \prod_{(u,i,j) \in D} \sigma(\bar{x}_{ui} - \bar{x}_{uj})$$

对于第二部分 $P(\theta)$ , 原作者大胆使用了贝叶斯假设, 即这个概率分布符合正太分布, 且对应的均值是0, 协方差矩阵是 $\lambda_\theta I$ , 即

$$P(\theta) \sim N(0, \lambda_\theta I)$$

原作者为什么这么假设呢? 个人觉得还是为了优化方便, 因为后面我们做优化时, 需要计算 $\ln P(\theta)$ , 而对于上面假设的这个多维正态分布, 其对数和 $\|\theta\|^2$ 成正比。即:

$$\ln P(\theta) = \lambda \|\theta\|^2$$

最终对于我们的最大对数后验估计函数

$$\ln P(\theta | >_u) \propto \ln P(>_u | \theta) P(\theta) = \ln \prod_{(u,i,j) \in D} \sigma(\bar{x}_{ui} - \bar{x}_{uj}) + \ln P(\theta) = \sum_{(u,i,j) \in D} \ln \sigma(\bar{x}_{ui} - \bar{x}_{uj}) + \lambda \|\theta\|^2$$

这个式子可以用梯度上升法或者牛顿法等方法来优化求解模型参数。如果用梯度上升法, 对 $\theta$ 求导, 我们有:

$$\frac{\partial \ln P(\theta | >_u)}{\partial \theta} \propto \sum_{(u,i,j) \in D} \frac{1}{1 + e^{\bar{x}_{ui} - \bar{x}_{uj}}} \frac{\partial (\bar{x}_{ui} - \bar{x}_{uj})}{\partial \theta} + \lambda \theta$$

由于

$$\bar{x}_{ui} - \bar{x}_{uj} = \sum_{f=1}^k w_{uf} h_{if} - \sum_{f=1}^k w_{uf} h_{jf}$$

这样我们可以求出:

$$\frac{\partial (\bar{x}_{ui} - \bar{x}_{uj})}{\partial \theta} = \begin{cases} (h_{if} - h_{jf}) & \text{if } \theta = w_{uf} \\ w_{uf} & \text{if } \theta = h_{if} \\ -w_{uf} & \text{if } \theta = h_{jf} \end{cases}$$

有了梯度迭代式子, 用梯度上升法求解模型参数就容易了。下面我们归纳下BPR的算法流程。

## 5. BPR算法流程

下面简要总结下BPR的算法训练流程:

输入: 训练集D三元组, 梯度步长 $\alpha$ , 正则化参数 $\lambda$ , 分解矩阵维度k。

输出: 模型参数, 矩阵 $W, H$

- 1. 随机初始化矩阵 $W, H$
- 2. 迭代更新模型参数:

$$w_{uf} = w_{uf} + \alpha \left( \sum_{(u,i,j) \in D} \frac{1}{1 + e^{\bar{x}_{ui} - \bar{x}_{uj}}} (h_{if} - h_{jf}) + \lambda w_{uf} \right)$$
$$h_{if} = h_{if} + \alpha \left( \sum_{(u,i,j) \in D} \frac{1}{1 + e^{\bar{x}_{ui} - \bar{x}_{uj}}} w_{uf} + \lambda h_{if} \right)$$

1. :	:
2. :	:
3. :	:
4. :	:
5. :	:
37.	:

### 评论排行榜

- 1. 梯度提升树(GBDT)原理小结
- 2. 集成学习之Adaboost算法原
- 3. 决策树算法原理(下)(323)
- 4. word2vec原理(二) 基于Hie
- 5. 强化学习(十六) 深度确定性

### 推荐排行榜

- 1. 梯度下降 (Gradient Desce
- 2. 奇异值分解(SVD)原理与在降
- 3. 梯度提升树(GBDT)原理小结
- 4. 谱聚类 (spectral clusterin
- 5. 集成学习之Adaboost算法原

$$h_{jf} = h_{jf} + \alpha \left( \sum_{(u,i,j) \in D} \frac{1}{1 + e^{\bar{x}_{ui} - \bar{x}_{uj}}} (-w_{uf}) + \lambda h_{jf} \right)$$

3. 如果 $W, H$ 收敛, 则算法结束, 输出 $W, H$ , 否则回到步骤2.

当我们拿到 $W, H$ 后, 就可以计算出每一个用户 $u$ 对应的任意一个商品的排序分:  $\bar{x}_{ui} = w_u \bullet h_i$ , 最终选择排序分最高的若干商品输出。

## 6. BPR小结

BPR是基于矩阵分解的一种排序算法, 但是和funktSVD之类的算法比, 它不是做全局的评分优化, 而是针对每一个用户自己的商品喜好分贝做排序优化。因此在迭代优化的思路完全不一样。同时对于训练集的要求也是不一样的, funktSVD只需要用户物品对应评分数据二元组做训练集, 而BPR则需要用户对商品的喜好排序三元组做训练集。

在实际产品中, BPR之类的推荐排序在海量数据中选择极少量数据做推荐的时候有优势, 因此在某宝某东等大厂中应用也很广泛。由于BPR并不复杂, 下一篇我会用tensorflow来做一个BPR的实践, 敬请期待。

(欢迎转载, 转载请注明出处。欢迎沟通交流: liujianping-ok@163.com)

分类: 0081, 机器学习

标签: 机器学习

好文要顶

关注我

收藏该文



刘建平Pinard

关注 - 16

粉丝 - 7512

加关注

« 上一篇: 特征工程之特征预处理  
» 下一篇: 用tensorflow学习贝叶斯个性化排序(BPR)

posted @ 2018-06-03 16:22 刘建平Pinard 阅读(29690) 评论(40) 编辑 收藏

刷新评论 刷新页面 返回顶部

- 登录后才能查看或发表评论, 立即 [登录](#) 或者 [逛逛](#) 博客园首页
- 【推荐】玩转开发板: 旧键盘+OpenHarmony 变身蓝牙键盘 v0.1
  - 【推荐】大型组态、工控、仿真、CAD\GIS 50万行VC++源码免费下载!
  - 【推荐】阿里云爆品销量榜单, 精选爆款产品低至0.55折
  - 【推荐】限时秒杀! 国云大数据魔镜, 企业级云分析平台

- 园子动态:
- 致园友们的一封信: 都是我们的错
  - 数据库实例 CPU 100% 引发全站故障
  - 发起一个开源项目: 博客引擎 fluss

- 最新新闻:
- 十问十答 | 建设空间站与探索火星、月球相比, 谁的意义更大?
  - Flash已死, 但这些古老的Flash游戏还在努力活着
  - 汉服投资有多火? 连B站、泡泡玛特都来了
  - 谁在抖音、快手直播间里寻找真爱?
  - 谷歌相册将于2021年6月告别不限量高品质云照片与视频存储
  - » 更多新闻...